

Surprise Adequacy (SA)

– SE4AI Präsentation –

Malte Grube¹

¹Dozentin: *Prof. Dr. rer. nat. Regina Hebig*
Universität Rostock

01. Juli 2026

- 1. Besonderheit von SA**
- 2. Funktionsweise von SA**
- 3. Hands-on Beispiel**
- 4. Repository-Erfahrungen**
- 5. Fazit**

Besonderheit von SA

Motivation

- **Softwareentwicklung:** Bewertung der Qualität von *Testfällen* (Statement-Coverage, Branch-Coverage, ...)
- **Neuronale Netze:** Keine Kontrollflussstrukturen
→ Metriken *nicht anwendbar* [KFY19; KFY23]

Metrik für neuronale Netze

- **Neuron Coverage (NC)** [Pei+17]: Wie viele Neuronen-Aktivierungen überschreiten *Schwellenwert* im Netz?
- **Problem:** *Kontinuierliche* Werte der Neuronen nicht ausreichend berücksichtigt [KFY19; KFY23]

Autoren von Surprise Adequacy (SA)

- **Kim et al.** [[KFY19](#); [KFY23](#)]: Messung der "Überraschung" einer *neuen Eingabe*
- In Relation zu den Trainingsdaten

Activation Traces (ATs)

- **Aktivierungen** der Neuronen einer Schicht im Netz
- Vektor als Muster für *jeweiliges* Input-Bild analysiert

Ziel von SA

- **Quantifizierung** der Vielfältigkeit einer Test-Suite
- Auch mit *manipulierten* Bildern möglich

Ziel von SA




Figure 1: Vorhersage einer "5". Das Test-Bild wurde mit hoher Wahrscheinlichkeit korrekt klassifiziert, während das FGSM-Bild stattdessen als "6" klassifiziert wurde.

Funktionsweise von SA

Grundlegendes Prinzip

1. Für jedes **Trainingsbeispiel**: Berechnung der ATs
2. Für jedes **Testbeispiel**: Berechnung der ATs
3. **SA**-Verfahren anwenden (LSA, DSA, MDSA)
4. **Ergebnis**: SA-Wert für jedes Testbeispiel
5. **Surprise Coverage (SC)**: Bewertung der Test-Suite

Likelihood-based SA (LSA)

1. **Train-ATs:** Kernel Density Estimation (KDE)
2. **Test-AT:** Berechnung der Dichte für x
3. *Niedrige Dichte $\rightarrow$ höhere Überraschung*

$$LSA(x) = -\log(\hat{f}(x))$$

Distance-based SA (DSA)

1. Berechnung 2 **Euklidischer Distanzen**:

- ① $dist_a$: Test-AT $\rightarrow$ nächster Train-AT *derselben* Klasse
- ② $dist_b$: Train-AT $\rightarrow$ nächsten Train-AT *anderer* Klasse

2. Für **Test-AT** x :

$$DSA(x) = \frac{dist_a}{dist_b}$$

- Kleiner Abstand zu **gleicher** Klasse $\rightarrow$ kleine DSA

Mahalanobis Distance-based SA (MDSA)

1. Für **Train-ATs**:

- ① Berechnung des Mittelwertsvektors μ (einmalig)
- ② Berechnung der Kovarianzmatrix C (einmalig)

2. Für **Test-AT** x :

$$MDSA(x) = \sqrt{(x - \mu)^T C (x - \mu)}$$

- Test-AT **nah am Zentrum** → niedrige MDSA
- Industrieller Einsatz durch **Effizienz** möglich

Surprise Coverage (SC)

- *Reminder zu NC*: #Neuronenakt. über Schwellenwert
- SC prüft **Vielfältigkeit** der Test-Suite via SA-Verteilung:
 1. n Buckets für SA-Werte definieren (z.B. $n = 1000$)
 2. LSA-Werte der **Testbeispiele** in Buckets einordnen
 3. $SC = \frac{\text{\#Buckets mit } \geq 1 \text{ Testbeispielen}}{n}$
 4. **Ergebnis**: Coverage-Wert zwischen $[0,1]$

Hands-on Beispiel

Hands-on: DSA mit MNIST

- **Annahme:** ATs liegen in 2D-Raum vor
- **Euklidischer Distanz** → DSA-Werte berechnen
- **Vier Punkte** im Raum (2x Test, 2x Train)
 1. Test-AT für Klasse "5": (3,2)
 2. Manipulierter Test-AT für Klasse "5": (10,8)
 3. Train-AT für Klasse "5": (2,2)
 4. Train-AT für Klasse "6": (6,2)

Repository-Erfahrungen

Repository-Erfahrungen I

- LSA mit MNIST lokal berechnet
- Test-Set und FGSM-Set analysiert
- Es folgen nun Plots...

Repository-Erfahrungen II




Figure 2: Akkumulierte LSA-Verteilungen für das MNIST-Testset zwischen Original- und FGSM-Bildern.

Repository-Erfahrungen III




Figure 3: LSA-Verteilungen für die Klasse "1".




Figure 4: LSA-Verteilungen für die Klasse "5".

Repository-Erfahrungen IV

- **Weitere** Adversarial-Datensätze einbauen, um schrittweise die Surprise Coverage zu erhöhen [KFY19; KFY23]
- Im Nachfolgepaper [KFY23]:
 - ▷ **LSC**: 34.1% auf 71%
 - ▷ **DSC**: 46% auf 74.2%
 - ▷ **MDSC**: 54.5% auf 82.2%

Fazit

Fazit I

- **SA:** Vielfalt von Test-Suites für NN quantifizieren
- **LSA, DSA, MDSA:** verschiedene Ansätze
- **SC:** Bewertung der Test-Suite basierend auf SA-Vielfalt

Fazit II

- Auswahl von Testfällen **über SA-Spektrum** hinweg sinnvoll für Retraining [KFY19]
- **Gewinn gering** in umfassenden Experimenten [KFY23]
- Im Gegensatz zu XAI kann SA **nicht angeben**, warum Modell Vorhersage getroffen hat

References

- [KFY19] Jinhan Kim, Robert Feldt, and Shin Yoo. “Guiding Deep Learning System Testing Using Surprise Adequacy”. In: *2019 IEEE/ACM 41st International Conference on Software Engineering (ICSE)*. 2019, pp. 1039–1049. DOI: [10.1109/ICSE.2019.00108](https://doi.org/10.1109/ICSE.2019.00108).
- [KFY23] Jinhan Kim, Robert Feldt, and Shin Yoo. “Evaluating Surprise Adequacy for Deep Learning System Testing”. In: *ACM Trans. Softw. Eng. Methodol.* 32.2 (Mar. 2023). ISSN: 1049-331X. DOI: [10.1145/3546947](https://doi.org/10.1145/3546947). URL: <https://doi.org/10.1145/3546947>.
- [Pei+17] Kexin Pei et al. “DeepXplore: Automated Whitebox Testing of Deep Learning Systems”. In: *Proceedings of the 26th Symposium on Operating Systems Principles*. SOSP '17. Shanghai, China: Association for Computing Machinery, 2017, pp. 1–18. ISBN: 9781450350853. DOI: [10.1145/3132747.3132785](https://doi.org/10.1145/3132747.3132785). URL: <https://doi.org/10.1145/3132747.3132785>.

Vielen Dank fürs Zuhören!